

부분 관측 경쟁 환경에서 팀-개인 보상 결합 가중치가 정책 안정성에 미치는 영향: 마피아 게임 사례 연구

박태주¹, 홍진원¹, 김창권¹, 김인중¹

¹한동대학교 AI 컴퓨터전자공학부

¹{21900323,hgg1hgf2,joeekim1025,ijkim}@handong.ac.kr

Impact of Team-Individual Reward Combination Weight on Policy Stability in Partially Observable Competitive Environments: A Mafia Game Case Study

Tae-Ju Park¹, Jin-Won Hong¹, Chang-Kwon Kim¹, In-Jung Kim¹

¹School of Artificial Intelligence, Computer and Electrical Engineering, Handong Global University

요약

팀 보상과 보조 보상(Auxiliary Reward)의 결합은 강화학습 에이전트의 학습을 돕는 일반적인 설계 기법이나, 보조 보상의 비중이 지나치게 높아질 경우 팀 목표와의 정렬 실패를 야기할 수 있다. 본 연구는 단순화된 마피아 게임 기반 POMDP 환경에서 팀-개인 보상 결합 가중치 λ 를 체계적으로 변화시키는 사례 연구를 수행하였다. PPO 알고리즘을 적용한 실험 결과, 보조 보상의 효과는 역할별로 상이하게 나타났다. 경찰과 의사는 적절한 λ 범위에서 보조 보상이 학습 신호를 강화하는 긍정적 효과를 보인 반면, 마피아는 보조 보상이 오히려 팀 목표와의 정렬을 저해하였다. 공통적으로 과도한 λ 에서는 역할에 따라 학습 실패 또는 팀 비정렬 수렴이 관찰되었다. 본 결과는 단일 환경에서의 사례 연구이나, 팀-개인 보상 결합 구조를 갖는 강화학습 시스템에서 보조 보상의 비중과 역할별 적합성이 중요한 설계 변수임을 시사한다.

1. 서론

부분 관측 마르코프 결정 과정(POMDP)은 에이전트가 환경의 전체 상태를 관측할 수 없는 구조로, 특히 다중 에이전트 경쟁 환경에서는 정보 비대칭성과 에이전트 간 상호작용이 학습 복잡도를 비선형적으로 증가시킨다. 이러한 환경에서 에피소드 종료 시에만 부여되는 희소 팀 보상(Sparse Team Reward)만으로는 학습 신호가 충분하지 않아, 실용적 이유에서 매 스텝 행동 단위로 부여되는 개별 밀집 보상(Dense Individual Reward)이 보조 신호로 함께 설계된다. 그러나 주 보상(Main Reward)과 보조 보상(Auxiliary Reward) 사이의 간극에서 에이전트는 보상 해킹으로 수렴할 가능성이 있다.

이에 본 연구는 이 불가피성을 전제로, 개별 보상 비중 λ 의 변화가 정책 안정성 및 역할별 성능에 미치는 영향을 실험적으로 규명하고, 보조 보상이 유효하게 작용하는 조건과 그렇지 않은 조건을 분석한다.

2. 배경

불완전 정보 사회적 추론 게임은 기만·연합·언어 협상 등 복잡한 창발적 행동을 연구하는 플랫폼으로 주목받고 있으며 [1, 2], 포텐셜 기반 보상 셰이핑은 최적 정책 불변성을 보장하는 이론적 기반을 갖는다 [3]. 타 에이전트 영향력을 내재적 동기로 활용한 협

력 유도 방법이 제안되었으나 [4], 개인-팀 보상 결합 비율이 역할별 정책 학습에 미치는 영향과 보조 보상이 유효하게 작용하는 조건에 대한 정량 분석은 미흡하다. 본 연구는 이 공백을 채운다.

3. 연구 방법

3.1. 실험 환경

진영	역할	인원	야간 행동
마피아	Mafia	2	에이전트 제거
시민	Police	1	역할 조사
	Doctor	1	에이전트 제거 무효
	Citizen	4	해당 없음

<표 1> 에이전트 구성

본 연구에서 사용하는 환경은 실제 마피아 게임을 단순화한 버전으로, 역할 구성 및 페이즈 규칙이 일반적인 마피아 게임과 상이할 수 있다. 게임의 한 에피소드는 크게 네 가지 단계로 구성된다. 먼저 토론 단계에서 생존 에이전트들이 순차 발언하고, 투표로 최대 득표자를 선정한다. 이후 처형 여부를 찬반 투표를 결정하며, 야간에는 생존한 특수 역할 에이전트가 역할별 행동을 수행한다.

$$\text{Citizen win} \Leftrightarrow |\mathcal{M}_{\text{alive}}| = 0$$

$$\text{Mafia win} \Leftrightarrow |\mathcal{M}_{\text{alive}}| \geq |\mathcal{C}_{\text{alive}}|$$

여기서 $\mathcal{M}_{\text{alive}}$, $\mathcal{C}_{\text{alive}}$ 는 각각 생존한 마피아 및 시민 진영 에이전트 집합이다. 에이전트의 발언은 자연어가 아닌 구조화된 행동 선택으로 구현된다. 토론 단계에서 에이전트 i 는 매 타 에이전트의 발언 차례마다 관측 벡터 o_t^i 를 입력받아 $(target_j, role_k)$ 쌍을 행동으로 출력한다. 타 에이전트의 발언은 관측 벡터 내 최근 이벤트 필드 및 누적 역할 선언을 통해 반영되어, 에이전트는 토론 전체 이력을 관측 공간에서 직접 수신한다. 투표 단계에서는 동일 구조로 처형 대상 $target_j$ 만 선택하며 역할 선언 차원은 마스킹된다. 야간 행동에서 Mafia는 제거 대상, Police는 수사 대상, Doctor는 보호 대상을 선택한다.

3.2. 보상 함수 설계

$$R_t^i = (1 - \lambda) \cdot R_{\text{team}}^i + \lambda \cdot R_{\text{individual}}^i, \quad \lambda \in [0, 1]$$

$$R_{\text{team}}^i = \begin{cases} +1, & \text{team win} \\ -1, & \text{team loss} \end{cases}$$

$$R_{\text{individual}}^i = \frac{1}{s} \sum_{e \in E_t} W[\rho_i][e][\rho_j(e)]$$

여기서 $W[\rho_i][e][\rho_j(e)]$ 는 역할 · 이벤트 · 대상역할 3 차원 보상 행렬, E_t 는 스텝 t 에서 발생한 이벤트 집합(처형, 살해, 역할 지목, 조사, 보호), $s = 10$ 은 스케일 상수이다. ρ_i 는 에이전트 i 의 역할(고정), $\rho_j(e)$ 는 이벤트 e 의 대상 플레이어의 실제 역할이다.

3.3. 에이전트 구조 및 PPO 설정

파라미터	값	파라미터	값
Learning Rate	1×10^{-4}	Clip	0.2
Discount	0.99	Entropy Coef.	0.05
GAE	0.95	Value Coef.	0.5
Epochs	10	Hidden Dim.	128

<표 2> 고정 하이퍼파라미터 표

에이전트의 관측 벡터 $o_t^i \in \mathbb{R}^{287}$ 은 다음 구성 요소의 연접이다. 자신의 상대적 ID one-hot(8), 역할 one-hot(4), 날짜(1) · 페이즈 one-hot(4: 토론/투표/처형/야간), 직전 이벤트 행위자 · 대상 · 역할 · 타입(30), 누적 투표 · 지목 · 보호 행렬 $8 \times 8 \times 3$ (192), 누적 역할 선언 행렬 8×5 (40), 생존 여부 one-hot(8)으로 구성된다.

입력 o_t^i 는 MLP 백본 $[287 \rightarrow 128 \rightarrow 128]$ (ReLU, Xavier 초기화)을 거쳐 Actor-Target 헤드 Linear(128 $\rightarrow$ 9), Actor-Role 헤드 Linear(128 $\rightarrow$ 5), Critic 헤드 Linear(128 $\rightarrow$ 1)로 분기된다. 유효하지 않은 행동은 로짓을 -10^9 으로 마스킹 후 결정한다. 각 역할을 독립 학습하며, 해당 역할 전체 슬롯을 PPO 에이전트로, 나머지 역할은 규칙 기반 에이전트로 구성한다.


본 연구의 PPO 업데이트 손실 함수는 다음과 같다.

$$\mathcal{L} = -\mathbb{E}_t[\min(r_t \hat{A}_t, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) \hat{A}_t)] + c_v \mathcal{L}_v - c_H H[\pi_\theta]$$

여기서 $r_t = \pi_\theta(a_t | o_t) / \pi_{\theta_{\text{old}}}(a_t | o_t)$ 는 중요도 비율, ϵ

은 클리핑 임계값, c_v 와 c_H 는 각각 가치 손실 및 엔트로피 보너스 계수이다.

4. 실험 결과




(그림 1) 역할 및 λ 에 따른 주요 학습 지표

실험은 $\lambda \in \{0.0, 0.1, 0.3, 0.5, 0.7, 0.9\}$ 에 대해 5,000 에피소드 이상 병렬 학습을 수행하였다. 그림 1의 각 행은 역할, 각 열은 KL Divergence(정책 업데이트 변동폭), Entropy(행동 다양성), Loss, Reward(에이전트 0 기준) 학습 곡선이다. 역할별로 상이한 수렴 패턴이 관찰되었다. 경찰은 $\lambda = 0.1$, 의사는 $\lambda = 0.3$ 에서 엔트로피가 빠르게 감소하며 Reward가 상승하는 정상 수렴 양상을 보인 반면, $\lambda = 0.9$ 에서 경찰은 엔트로피 감소에 실패하고 마피아는 엔트로피가 단독으로 급락하며 단순 전략으로 조기 수렴하였다. 시민의 경우 $\lambda = 0.9$ 에서 KL Divergence가 지속 상승하는 불안정 양상이 나타났다.

학습이 이상적으로 진행될 경우 KL Divergence와 Loss는 감소하며 안정 수렴하고, Reward는 증가하는 양상을 보여야 한다. 또한 그림 1의 Reward는 λ 마다 보상 함수의 구성과 스케일이 달라지므로 λ 간 직접 비교가 불가하며, 역할별 실제 성능 비교는 λ 에 독립적인 승률 기준을 기준으로 해석한다. 에이전트 0은 각 역할군 내 첫 번째 학습 에이전트를 의미한다.

4.1. 승률 분포



(그림 2) 역할 및 λ 에 따른 최종 승률 변동성

Role	F-value	p-value
Mafia	10.02	< 0.001
Police	139.96	< 0.001
Doctor	73.97	< 0.001
Citizen	7.00	< 0.001


<표 3> λ 값 변화에 따른 역할군별 승률 차이 분석

그림 2 에서 역할별 최적 λ 가 상이하게 나타났다. Mafia 는 $\lambda = 0.0$, Police 는 $\lambda = 0.1$, Doctor 는 $\lambda = 0.3$, Citizen 은 $\lambda = 0.7$ 에서 최고 승률을 보였다. 이는 팀 보상과 개인 보상 간 상관관계의 일관성이 역할마다 다르기 때문으로 해석된다. 마피아의 야간 제거 행동은 팀 승패와 직결되어 보조 보상이 오히려 목표 정렬을 저해하는 반면, 경찰·의사·시민은 정보 수집·보호·추론이라는 간접적 기여 구조상 적절한 보조 보상이 학습에 도움을 주는 것으로 나타났다.

표 3 은 λ 를 독립변수, 각 역할의 에피소드 승률을 종속변수로 설정한 일원배치 ANOVA 결과이다. 경찰 ($F=139.96$)의 높은 F-value 는 경찰 승률이 λ 변화에 가장 민감함을 의미하며, 전 역할 $p < 0.001$ 로 통계적으로 유의하다.

4.2. 전략적 엔트로피 및 KL Divergence

Impact of Reward Weight on Entropy and Performance



(그림 3) λ 에 따른 전략적 엔트로피와 승률 추이

그림 3 에서 전략적 엔트로피와 승률의 관계는 역할마다 상이하게 나타났다. 마피아는 λ 증가에 따라 전략적 엔트로피가 단조 증가하며 승률이 단조 감소하는 강한 음의 상관관계를 보였다($r_{\text{Mafia}} = -0.984$). 이는 보조 보상이 팀 승패와 직결된 마피아의 행동 목표와 충돌하여 팀 비정렬 전략으로의 수렴을 유도하는 것으로 해석된다. 반면 경찰과 의사는 각각 $\lambda = 0.1$, $\lambda = 0.3$ 에서 전략적 엔트로피가 최소화되며 승률이 최대화되는 비단조적 패턴을 보였다($r_{\text{Police}} = -0.866$). 이는 적절한 보조 보상이 역할 특화 행동(수사, 보호)을 명확화하는 보조 보상 신호로 작용함을 시사한다. 시민의 경우 λ 에 따른 엔트로피 및 승률 변화폭이 타 역할 대비 상대적으로 작아, 보조 보상 민감도가 낮은 것으로 나타났다. 결과적으로 본 사례 연구에서 보조 보상의 효과는 팀 목표와의 정렬도에 따라 역할별로 상이하며, 과도한 $\lambda (= 0.9)$ 는 역할에 관계없이 학습 실패 또는 팀 비정렬 수렴을 유발하였다.

5. 논의 및 한계

팀 목표와 행동이 직결되는 마피아는 보조 보상이 목표 정렬을 저해한 반면, 간접적으로 기여하는 경찰·의사는 적절한 λ 에서 학습 효율이 향상되었다. 공통적으로 과도한 $\lambda (= 0.9)$ 는 역할에 관계없이 학습 실패 또는 팀 비정렬 수렴을 유발하였다. 단, 본 결과는 마피아 8 인 환경과 고정된 신경망 구조에 국한되며, 최적 λ 의 위치는 환경·역할 구조에 따라 달라질 수 있다. 또한 본 실험에서는 모든 역할에 동일한 λ 를 적용하였으나, 역할별 최적 λ 가 상이하게 나타난 점은 역할마다 독립적인 λ 를 적용하는 방식이 성능을 더욱 개선할 가능성을 시사하며, 이는 향후 연구 과제로 남긴다. 실험 결과는 초반 높은 λ 로 보조 보상을 활용한 뒤 학습 진행에 따라 λ 를 감소시키는 전략이 보조 보상의 긍정적 효과와 부작용을 동시에 완화할 수 있음을 시사한다.

6. 결론

본 연구는 POMDP 기반 경쟁 환경에서 개인 보상 가중치 λ 가 역할별 정책 안정성에 미치는 영향을 분석하였다. 실험 결과, 보조 보상의 효과는 팀 목표와의 정렬도에 따라 역할별로 상이하며, 단일 임계점보다는 역할 구조에 따른 최적 λ 범위가 존재함을 확인하였다. 공통적으로 과도한 λ 는 역할에 관계없이 성능 저하를 유발하였다. 본 결과는 단순화된 마피아 게임이라는 단일 환경에서의 사례 연구이나, 팀-개인 보상 결합 구조를 갖는 강화학습 시스템에서 보조 보상의 비중과 역할 적합성이 중요한 설계 변수로 작용할 수 있음을 시사하며, 향후 다양한 환경에서의 일반화 검증이 필요하다.

사 사

본 연구는 2026년 과학기술정보통신부 및 정보통신기획평가원의 SW 중심대학사업 지원을 받아 수행되었음 (2023-0-00055).

참고문헌

- [1] Serrino, J., Kleiman-Weiner, M., Parkes, D. C., & Tenenbaum, J. B. (2019). Finding Friend and Foe in Multi-Agent Games. *Advances in Neural Information Processing Systems (NeurIPS)*.
- [2] Light, A., et al. (2023). AvalonBench: Evaluating LLMs Playing the Deduction Game Avalon. *arXiv preprint arXiv:2310.05036*.
- [3] Ng, A. Y., Harada, D., & Russell, S. (1999). Policy invariance under reward transformations: Theory and application to reward shaping. *International Conference on Machine Learning (ICML)*.
- [4] Jaques, N., Lazaridou, A., Hughes, E., Gulcehre, C., Ortega, P., Strouse, D., ... & De Freitas, N. (2019). Social Influence as Intrinsic Motivation for Multi-Agent Deep Reinforcement Learning. *International Conference on Machine Learning (ICML)*.